




# SAE

## Prédiction d'une variable quantitative




Fait par:

**ROCA--LABUTTIE Joackim**  
**HALLER Fabian**





# Sommaire

- Résumé : Mes premiers pas en Machine Learning
  - Démarche de résolution : De l'exploration à la modélisation
  - Résultats des modèles et choix final
  - Annexe : Codes Python complets
- 
- 
- 

## 1. Résumé de ce que j'ai retenu du Machine Learning

Le Machine Learning (ou Apprentissage Automatique) est un domaine de l'intelligence artificielle qui permet aux ordinateurs d'apprendre à partir de données sans être explicitement programmés pour une tâche précise. Dans le cadre de l'apprentissage supervisé, et plus spécifiquement de la régression, l'objectif est de prédire une variable cible quantitative (Y) en s'appuyant sur un ensemble de variables explicatives ou prédicteurs.

Les points clés retenus de cette démarche sont :

- **La préparation des données** : C'est une étape cruciale. Il faut analyser, nettoyer et préparer les données brutes (traitement des valeurs manquantes et gestion des valeurs aberrantes ou extrêmes).
- **La modélisation** : Il s'agit de choisir l'algorithme le plus adapté (ici, la Régression Linéaire Multiple sous Scikit-Learn) pour modéliser la relation entre les variables.
- **L'évaluation** : Le modèle doit être évalué via des métriques d'erreur (comme le RMSE ou le  $R^2$ ) pour s'assurer de sa capacité à généraliser ses prédictions sur de nouvelles données.

## 2. Démarche de résolution

Notre objectif est de prédire le diamètre d'une tumeur cancéreuse (Y) à l'aide de 10 tests médicaux quantitatifs. La démarche mise en place est la suivante :

**1.Exploration des données (EDA)** : Chargement du fichier cancer\_sae2026.csv et analyse descriptive pour identifier la distribution des variables et la présence de valeurs manquantes ou extrêmes.

**2.Imputation des valeurs manquantes** : Remplacement des données manquantes par la médiane ou la moyenne pour ne pas perdre d'observations précieuses.

**3.Traitement des valeurs extrêmes** : Afin d'évaluer la robustesse de notre modèle, nous avons créé trois jeux de données distincts :

- Un jeu de données où les valeurs extrêmes (détectées via la méthode de l'écart interquartile - IQR) sont supprimées.
- Un jeu de données avec écrêtement (capping/winsorisation), où les valeurs extrêmes sont plafonnées aux bornes acceptables.
- Le jeu de données original conservant toutes les valeurs extrêmes.

**4. Modélisation et Évaluation :** Entraînement d'un modèle de Régression Linéaire Multiple (RLM) sur les trois scénarios, puis comparaison de leurs performances (Erreur Quadratique Moyenne et coefficient de détermination  $R^2$ ) pour sélectionner le meilleur modèle.

### 3. Résultats des modèles et choix final :

Après avoir entraîné une Régression Linéaire Multiple (RLM) sur nos données pour prédire le diamètre de la tumeur, voici les métriques obtenues (RMSE pour l'erreur moyenne de prédiction, et  $R^2$  pour la part de variance expliquée par le modèle) :

- **Scénario 1 : Avec les valeurs extrêmes (données brutes)**

Le modèle a obtenu un  $R^2$  de 0.9027 et un RMSE de 0.0205. C'est notre modèle de base.

- **Scénario 2 : Sans les valeurs extrêmes (suppression)**

Le modèle a obtenu un  $R^2$  de 0.9070 et un RMSE de 0.0204. Le  $R^2$  est le plus élevé ici, ce qui est logique : en supprimant les cas "difficiles" (les tumeurs atypiques), le modèle explique plus facilement les cas restants.

- **Scénario 3 : Après écrêtement (capping/winsorisation)**

Le modèle a obtenu un  $R^2$  de 0.9042 et un RMSE de 0.0203. C'est ici que l'erreur de prédiction (RMSE) est la plus faible.


#### Mon modèle préféré : Le modèle "Après écrêtement"

Bien que le scénario sans les valeurs extrêmes affiche le meilleur score  $R^2$  (0.9070), mon choix se porte sur la méthode de l'écrêtement. Voici pourquoi :

- **Minimisation de l'erreur absolue :** Le but premier dans le domaine médical est d'avoir la prédiction de la taille de la tumeur la plus proche de la réalité. Le modèle écrêté possède le RMSE le plus bas (0.0203), ce qui signifie que ses prédictions sont en moyenne les plus précises.
- **Conservation de l'information médicale :** Supprimer purement et simplement les valeurs extrêmes (Scénario 2) est dangereux en médecine. Un patient avec des résultats atypiques reste un patient qu'il faut pouvoir diagnostiquer.
- **Robustesse :** L'écrêtement permet de limiter l'influence démesurée qu'ont les valeurs aberrantes sur la droite de régression (qui utilise la méthode des moindres carrés, très sensible aux extrêmes), tout en conservant 100% des effectifs de notre base de données. C'est le meilleur compromis entre performance mathématique et réalité métier.

## Visualisation des performances du modèle choisi :

Pour confirmer la pertinence de ce choix, le graphique ci-dessous compare les diamètres réels des tumeurs avec les diamètres prédits par notre modèle écrêté.



On observe que les prédictions (points bleus) suivent de très près la ligne de prédiction parfaite (en pointillés rouges). Cela confirme visuellement la robustesse de notre modèle, qui parvient à estimer la taille de la tumeur avec une grande précision, y compris pour les valeurs les plus grandes grâce à l'écrêtement.

## 4. Annexe : Codes Python complets

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
```

```

# =====
# 1. Chargement et préparation des données
# =====
df = pd.read_csv('cancer_sae2026.csv', sep=';')
# Suppression de la colonne 'identifiant' (elle ne sert pas à
prédire le cancer !)
if 'identifiant' in df.columns:
    df = df.drop('identifiant', axis=1)
# Forcer la conversion en nombres et traiter les valeurs manquantes
df = df.apply(pd.to_numeric, errors='coerce')
df = df.fillna(df.median())
# =====
# 2. Fonction pour détecter et traiter les outliers (Méthode IQR)
# =====
def handle_outliers_iqr(df_in, col_name, method='keep'):
    q1 = df_in[col_name].quantile(0.25)
    q3 = df_in[col_name].quantile(0.75)
    iqr = q3 - q1
    lower_bound = q1 - 1.5 * iqr
    upper_bound = q3 + 1.5 * iqr

    if method == 'drop':
        # Sans les valeurs extrêmes
        return df_in[(df_in[col_name] >= lower_bound) & (df_in[col_name]
<= upper_bound)]
    elif method == 'cap':
        # Après écrêtement
        df_out = df_in.copy()
        df_out[col_name] = np.clip(df_out[col_name], lower_bound,
upper_bound)
        return df_out
    return df_in
# =====
# 3. Création des 3 jeux de données
# =====
# a. Avec les valeurs extrêmes (Original)
df_keep = df.copy()
# b. Sans les valeurs extrêmes
df_drop = df.copy()
for col in df_drop.columns:
    df_drop = handle_outliers_iqr(df_drop, col, method='drop')
# c. Après écrêtement
df_cap = df.copy()
for col in df_cap.columns:
    df_cap = handle_outliers_iqr(df_cap, col, method='cap')

```

```

# =====
# 4. Fonction de modélisation (RLM)
# =====
def train_and_evaluate(df_data, scenario_name):
    # On indique ici le vrai nom de la colonne cible : 'y' minuscule
    X_data = df_data.drop('y', axis=1)
    y_data = df_data['y']

    # Séparation train / test (80% / 20%)
    X_train, X_test, y_train, y_test = train_test_split(X_data, y_data,
test_size=0.2, random_state=42)

    # Entraînement du modèle
    model = LinearRegression()
    model.fit(X_train, y_train)

    # Prédiction
    y_pred = model.predict(X_test)

    # Évaluation
    rmse = np.sqrt(mean_squared_error(y_test, y_pred))
    r2 = r2_score(y_test, y_pred)

    print(f"--- Résultats pour : {scenario_name} ---")
    print(f"RMSE : {rmse:.4f}")
    print(f"R² : {r2:.4f}\n")
    return r2

# =====
# 5. Lancement des modélisations et résultats
# =====
print("ÉVALUATION DES PERFORMANCES DES MODÈLES\n")
score_keep = train_and_evaluate(df_keep, "Avec valeurs extrêmes")
score_drop = train_and_evaluate(df_drop, "Sans valeurs extrêmes")
score_cap = train_and_evaluate(df_cap, "Après écrêtement")
# =====
# 6. BONUS : Graphique Valeurs Réelles vs Prédiction (Modèle Écrêté)
# =====
print("Génération du graphique pour le modèle écrêté...")
X_cap = df_cap.drop('y', axis=1)
y_cap = df_cap['y']
X_train, X_test, y_train, y_test = train_test_split(X_cap, y_cap,
test_size=0.2, random_state=42)
model_cap = LinearRegression()
model_cap.fit(X_train, y_train)
y_pred_cap = model_cap.predict(X_test)
plt.figure(figsize=(8, 6))
plt.scatter(y_test, y_pred_cap, color='blue', alpha=0.6, label='Prédiction')

```

```
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'r--',  
         lw=2, label='Prédiction parfaite')  
plt.xlabel('Diamètre Réel de la Tumeur')  
plt.ylabel('Diamètre Prédit par le Modèle')  
plt.title('Modèle Écrêté : Valeurs Réelles vs Prédiction')  
plt.legend()  
plt.grid(True)  
plt.show()
```